# STL和字符串处理

(OOP)

黄民烈

aihuang@tsinghua.edu.cn

http://coai.cs.tsinghua.edu.cn/

课程团队: 刘知远 姚海龙 黄民烈

## 上期要点回顾

- 类模板与函数模板特化
- 命名空间
- STL初步—容器与迭代器

# 本讲内容提要

- string字符串类
- iostream输入输出流
- 字符串处理与正则表达式

# string 字符串类

# 变长字符串

- ■字符串是char的数组
- ■但如果我们无法提前确认字符串长度?
  - vector<char>?

- ■STL为我们提供了更方便的string类型
  - 允许简洁的拼接操作
     string fullname = firstname + " " + lastname;
  - 也能够使用惯用的输入输出方法 cout << fullname << endl;</li>

#### ■构造方式

#### ■转换为c风格字符串

• str.c\_str() //注意返回值为常量字符指针(const char\*), 不能修改

#### ■和vector类似

#### ■不同之处

- · 查询长度也可以使用str.length(), 与size()返回值相同
- 向尾部增加也可以使用 str += 'a' 或者 str += s2

#### ■三种输入方式

读取可见字符直到遇到空格 cin >> firstname; //Mike

```
输入文本
Mike William
Andy William
#
```

- 读一行 getline(cin, fullname); //Mike William
- 读到指定分隔符为止(可以读入换行符)
   getline(cin, fullnames, '#');
   //"Mike William\nAndy William\n"

#### ■拼接

- string fullname = firstname + " " + lastname;
- 注意: 拼接的时间复杂度为生成的字符串长度
- 例如:

```
for(int i = 0; i < n; i++)
    allname = allname + name[i] + "\n"
//时间复杂度O(n^2*L)的时间, L表示每个子串的平均长度
```

• 拼接多个字符串最好使用 operator+= 或者 stringstream

#### ■比较

- 我们可以直接使用运算符比较字符串字典序
- string a = "alice", b = "bob";
- a == b //False a < b //True

#### ■数值类型字符串化

```
    to_string(1) //"1"
    to_string(3.14) //"3.14"
    to_string(3.1415926) //"3.141593" 注意精度损失
    to_string(1+2+3) //"6"
```

#### ■字符串转数值类型

```
• double e = stod("34.5") //e=34.5
```

# 对于 std::string 和 std::vector<char>定义的字符串 str,以下选项正确的是:

- A 都可以使用 str.length();获得字符串长度
- B 都可以使用 for(char c: str)遍历字符串中的所有字符
- 都可以使用 cin>>str;从标准输入输入字符串
- 都可以使用 str+="abc";向字符串尾部添加字符

# iostream 输入输出流


### 回忆:重载输出流运算符

```
cout << str << endl;
cin >> str;

ostream& operator<<(ostream& out, const Test& src)
{
   out << src.id << endl;
   return out;
}</pre>
```

■ostream到底是什么?

# STL输入输出流



## 从ostream和cout开始

- ■ostream即output stream
  是STL库中所有输出流的基类
- ■它重载了针对基础类型的输出流运算符(<<) 接受不同类型的数据,再调用系统函数进行输出
- 统一了输出接口,改善了C中输出方式混乱的状况 printf("%d %f %s", 1, 2.3, "hello");

http://www.cplusplus.com/reference/ostream/ostream/operator%3C%3C/

- cout是STL中内建的一个ostream对象
- ■它会将数据送到标准输出流(一般是屏幕)

## 实现自己的ostream

```
class ostream
public:
                                    int main()
   ostream& operator<<(char c)</pre>
                                       cout << "hello" << ' '</pre>
      printf("%c", c);
                                           << "world";
      return *this;
                                        return 0;
   ostream& operator<<(const char* str)</pre>
      printf("%s", str);
                          实现原理:
      return *this;
                          《〈运算符为左结合
}cout;
先执行cout << "hello" 调用第二个函数 返回c1 (cout的引用)
再执行c1 << ''调用第一个函数 返回c2 (cout的引用)
最后执行c2 << "world" 调用第二个函数
```

## 格式化输出

■如何格式化输出 - #include <iomanip>

```
cout << fixed << 2018.0 << " " << 0.0001 << endl;</pre>
            //浮点数 -> 2018.000000 0.000100
cout << scientific << 2018.0 << " " << 0.0001 << endl;</pre>
            //科学计数法 -> 2.018000e+03 1.000000e-04
cout << defaultfloat; //还原默认输出格式
cout << setprecision(2) << 3.1415926 << endl;</pre>
            //输出精度设置为2 -> 3.2
cout << oct << 12 << " " << hex << 12 << endl;
            //八进制输出 -> 14 十六进制输出 -> c
cout << dec; //还原十进制
cout << setw(3) << setfill('*') << 5 << endl;</pre>
            //设置对齐长度为3,对齐字符为* -> **5
```

# 格式化输出

#### ■以setprecision为例

- cout << setprecision(2) << 1.05 << endl;</li>
- 保留2位精度, 输出1.1

#### ■如何实现?

- C++标准中未定义,不同编译器有自己的实现方式
- 一种实现方式的示例

```
class setprecision
{
private:
    int precision;
public:
    setprecision(int p) : precision(p) {}
    friend class ostream;
};
// setprecision(2) 是一个类的对象
```

# 流操纵算子(stream manipulator)

```
class ostream
                               ■借助辅助类,
                                 设置成员变量
private:
  int precision; //记录流的状态
                               ■这种类叫
public:
                                 流操纵算子
  ostream& operator<<
        (const setprecision &m) {
     precision = m.precision;
     return *this;
} cout;
  cout << setprecision(2);</pre>
   // setprecision(2) 是一个类的对象
```

### 流操纵算子: endl

#### ■C++标准中endl的声明

ostream& endl(ostream& os);

#### ■end1是一个函数

• 等同于输出'\n', 再清空缓冲区 os.flush()

```
ostream& endl(ostream& os) {
   os.put('\n');
   os.flush();
   return os;
}
```

• 可以调用 endl(cout);

#### ■缓冲区

- 目的是减少外部读写次数
- 写文件时,只有清空缓冲区或关闭文件才能保证内容正确写入

### 流操纵算子: endl

- ■endl同时也是流操纵算子,如何实现?
   cout << endl;
- ■一种实现方式的示例

```
ostream& operator<<
    (ostream& (*fn)(ostream&)) {
    //流运算符重载,函数指针作为参数
    return (*fn)(*this);
}
```

### 不能复制的cout

■注意重载流运算符的方式

```
ostream& operator<<(const char &c)
friend ostream& operator<<(ostream& os, MyClass obj)</pre>
```

- ■为什么重载流运算符要返回引用?
  - 避免复制

- ■观察ostream的复制构造函数
  - ostream(const ostream&) = delete;
  - ostream(ostream&& x);
  - 禁止复制、只允许移动
  - 仅使用cout一个全局对象

# 不能复制的cout

#### ■为什么只能使用一个对象?

- 减少复制开销
- · 一个对象对应一个标准输出,符合00P思想
- 多个对象之间无法同步输出状态

#### ■是否能做得更好?

- 全局对象往往引入初始化顺序问题
- 单件模式 (Singleton Pattern)
- 在之后的设计模式中会介绍

#### 下列说法正确的是

- 流插入运算符<<的两个参数一定是istream& 和T&,其中T是基础类型或自定义类型。
- B cin和cout是类,而不是对象
- 重载流运算符要返回引用的原因是避免复制
- □ 流操纵算子endl等同于输出'\n'

### 文件输入输出流

- ■以文件输入流作为例子
- ■ifstream是istream的子类
- ■功能是从文件中读入数据

#### ■打开文件

- ifstream ifs("input.txt");
- ifstream ifs("binary.bin", ifstream::binary); //以二进制形式打开文件
- ifstream ifs;
   ifs.open("file")
   //do something
   ifs.close()

## 读入示例

```
#include <iostream>
#include <string>
#include <cctype>
#include <fstream>
using namespace std;
int main() {
   ifstream ifs("input.txt");
   while(ifs) { //判断文件是否到末尾 利用了重载的bool运算符
       ifs >> ws; //除去前导空格 ws也是流操纵算子
       int c = ifs.peek(); //检查下一个字符,但不读取
       if (c == EOF) break;
       if (isdigit(c)) //<cctype>库函数
       {
           int n;
           ifs >> n;
           cout << "Read a number: " << n << endl;</pre>
       } else {
           string str;
           ifs >> str;
           cout << "Read a word: " << str << endl;</pre>
```

## 其他操作

- ■getline(cin, str)
  - ifstream是istream的子类
  - 故getline(ifs, str)仍然有效

#### ■其他操作

- get() 读取一个字符
- ignore(int n=1, int delim=EOF) 丢弃n个字符,或者直至遇到delim分隔符
- peek() 查看下一个字符
- putback(char c) 返还一个字符
- unget() 返还一个字符


• .....

## istream与scanf

- ■为什么C++使用流输入取代了scanf
  - Scanf不友好,不同类型要使用不同的标识符 scanf("%d %hd %f %lf %s", &i, &s, &f, &d, name); cin >> i >> s >> f >> d >> name;
  - 安全性 scanf("%d %d", &a); //可能写入非法内存
  - 可拓展性MyClass obj;cin >> obj;
  - 性能 scanf在运行期间需要对格式字符串进行解析 istream在编译期间已经解析完毕

# 字符串输入输出流

- ■以输入输出流作为例子
- ■stringstream是iostream的子类
- ■iostream继承于istream和ostream
- ■stringstream实现了输入输出流双方的接口



# stringstream

#### ■stringstream

- 它在对象内部维护了一个buffer
- 使用流输出函数可以将数据写入buffer
- 使用流输入函数可以从buffer中读出数据

#### ■一般用于程序内部的字符串操作

#### ■构造方式

- stringstream ss; //空字符串流
- stringstream ss(str); //以字符串初始化流

# 使用示例

```
#include <sstream>
using namespace std;

int main() {
    stringstream ss;
    ss << "10";
    ss << "0 200";

    int a, b;
    ss >> a >> b; //a=100 b=200
}
```

- ■可以连接字符串
- ■可以将字符串转换为其他类型的数据
- ■配合流操作算子,可以达到格式化输出效果

# 获取stringstream的buffer


- ■ss.str()
  - · 返回一个string对象
  - 内容为stringstream的buffer

#### ■注意buffer内容并不是未读取的内容

```
#include <sstream>
#include <iostream>
using namespace std;
int main() {
   stringstream ss;
   ss << "100 200";
   cout << ss.str() << endl; //输出"100 200"
   int a;
   ss >> a;
   cout << ss.str() << endl; //输出"100 200"
   return 0;
```

# 获取stringstream的buffer

```
int main()
   stringstream ss;
   ss << "100 200";
   cout << ss.str() << endl;</pre>
    //"100 200"
   int a, b;
   ss >> a; // a = 100
   cout << ss.str() << endl;</pre>
   //"100 200"
   ss >> b; // b = 200
   return 0;
```



# 实现一个类型转换函数

- ■如何实现字符串与整数的互相转换?
  - to\_string 转换为字符串
  - stoi 转换为整数
- ■其他类型呢?可以使用一个函数实现吗?

```
#include <iostream>
#include <sstream>
using namespace std;

int main() {
    string x = convert<string>(123);
    int y = convert<int>("456");
    cout << x << endl;
    cout << y << endl;
    return 0;
}</pre>
```

## 实现一个类型转换函数

```
template<class outtype, class intype>
outtype convert(intype val)
  static stringstream ss;
                //使用静态变量避免重复初始化
  ss.str(""); //清空缓冲区
  ss.clear(); //清空状态位(不是清空内容)
  ss << val;
  outtype res;
  ss >> res;
  return res;
      关于状态位:
      http://www.cplusplus.com/reference/ios/ios/setstate/
```

#### 下列说法 错误 的是

- A scanf有可能写入非法内存
- **B** stringstream是继承自iostream的子类
- stringstream既可以作为输入流,也可以 作为输出流
- ifstream是iostream的子类,能同时从文件中读入数据和写出数据

## 字符串处理与正则表达式

### 用户名注册

#### ■场景: 用户名注册


只能包含小写字母、数字、下划线,并且限制用户名 长度在3~15个字符之间

```
合法例子: john_123
非法例子: John 123 / jo / @john
```

• 如何处理?

### 正则表达式

- ■正则表达式:由字母和符号组成的特殊文本,搜索文本时定义的一种规则
- ■场景:用户名注册
  - 只能包含小写字母、数字、下划线和连字符,并且限制用户名长度在3~15个字符之间
  - 使用正则表达式表示规则



### 正则表达式

### ■正则表达式的三种模式

- 匹配:判断整个字符串是否满足条件 ^[a-z0-9\_]{3,15}\$
   能与john\_123匹配,不能与Jo匹配
- 搜索: 符合正则表达式的子串 在"q123e456w"找出所有数字串 [0-9]+ 搜索结果 123, 456
- 替换:按规则替换字符串的子串
   给定"q123e456w"将所有数字串替换为(number)
   替换结果 q(123)e(456)w

### 如何编写正则表达式?

### 基本模式匹配

### ■字符代表其本身

•如:使用the进行搜索,可以找到句中所有的"the" The car parked in the garage.

#### ■转义字符

• \n表示换行、\t表示制表符

### ■特殊匹配字符

- ^代表字符串开头,\$代表字符串结尾
- 如: ^\t只能匹配到以制表符开头的内容
- 如: ^bucket\$只能匹配到只含bucket的内容

### 字符簇

### ■匹配的单个字符在某个范围中

- [aeiou] 匹配任意一个元音字符
- [a-z] 匹配所有单个小写字母
- [0-9] 匹配所有单个数字

#### ■范围取反

- · [^a-z] 匹配所有非小写字母的单个字符
- [^c]ar: The car parked in the garage.

#### ■连用

- [a-z][0-9] 匹配所有字母+数字的组合,比如a1、b9
- ^[^0-9][0-9]\$ 匹配长度为2的内容,且第一个不为数字,第二个为数字
- [Tt]he: The car parked in the garage.

### 字符簇

#### ■特殊字符

- •. 匹配除换行以外任意字符, [.]或\. 可表示匹配句号
  - .ar: The car parked in the garage.
  - ge[.]: The car parked in the garage.
- \d 等价[0-9], 匹配所有单个数字
- \D 等价[^0-9], 匹配所有单个非数字
- \s 匹配所有空白字符,如\t,\n
- \S 匹配所有非空白字符
- \w 匹配字母、数字、下划线,等价[a-zA-Z0-9\_]
- \W 匹配非字母、数字、下划线,等价[^a-zA-Z0-9\_]

## 下列符合正则表达式^[0-9]\w\.\D[^0-9]\$的字符串是

- A 20.3w
- B 4s.s4
- **13\_3**
- 0\_.\_w

#### 参考:

\D: 匹配所有单个非数字

\w: 匹配字母、数字、下划线

.: 匹配非换行任意字符

\.:匹配.

### 重复模式

### ■x{n,m}代表前面内容出现次数重复n~m次

- a{4} 匹配aaaa
- a{2,4} 匹配aa、aaa、aaaa
- a{2,} 匹配长度大于等于2的a

### ■扩展到字符簇

- [a-z]{5,12} 代表为长度为5~12的英文字母组合
- .{5} 所有长度为5的字符

### ■特殊字符

- ? 等价{0,1}
  - [T]?he: The car parked in the garage.
- · + 等价{1,}
  - c.+e: The car parked in the garage.
- •\* 等价{0,}
  - [a-z]\*: The car parked in the garage.

### 或连接符

### ■匹配模式可以使用' | 进行连接

- (Chapter | Section) [1-9][0-9]? 可以匹配Chapter 1、Section 10等
- 0\d{2}-\d{8}|0\d{3}-\d{7} 可以匹配010-12345678、0376-2233445
- (c|g|p)ar: The car parked in the garage.

### ■使用()改变优先级

- m food 可以匹配 m 或者 food
- (m|f)ood 可以匹配 mood 或者 food
- (T|t)he|car: The car parked in the garage.

### 正则表达式辅助工具

#### ■动态匹配

- 可以反复测试
- 以染色区分匹配部分



http://tool.chinaz.com/regex/

### 正则表达式库 < regex >

- ■如何在C++中使用正则表达式
  - <regex>库
- ■创建一个正则表达式对象
  - regex re("^[1-9][0-9]{10}\$") 11位数
  - 注意: C++的字符串中"\"也是转义字符
    - ·如果需要创建正则表达式"\d+",应该写成
    - regex re("\\d+")

### 原生字符串

### ■原生字符串

- 原生字符串可以取消转义, 保留字面值
- 语法: R"(str)" 表示str的字面值
- "\\d+" = R"(\d+)" = \d+
- 原生字符串能换行,比如 string str = R"(Hello World)";
- 结果str = "hello\nWorld"

### 正则表达式库 <regex>

#### ■匹配

• regex\_match(s, re): 询问字符串s是否能完全匹配 正则表达式re

```
#include <iostream>
#include <string>
#include <regex>
using namespace std;
int main() {
   string s("subject");
   regex e("sub.*");
   smatch sm;
   if(regex_match(s,e))
                                      输出: matched
      cout << "matched" << endl;</pre>
}
```

### 捕获和分组

- ■有时我们想要获取匹配每一个部分的细节
  - 例如:在 \w\*\d\* 中,我们想知道 \w\*和\d\*分别匹配了什么
- ■使用()进行标识,每个标识的内容被称作分组
  - 正则表达式匹配后,每个分组的内容将被捕获
  - •用于提取关键信息,例如version(\d+)即可捕获版本号

### 正则表达式库 <regex>

#### ■匹配和捕获

• regex\_match(s, result, re): 询问字符串s是否能完全匹配正则表达式re, 并将捕获结果储存到result中

• result需要是smatch类型的对象

```
#include <iostream>
#include <string>
#include <regex>
using namespace std;
int main () {
    string s("version10");
                                                          输出:
    regex e(R"(version(\d+))"); smatch sm;
    if(regex match(s,sm,e)) {
         cout << sm.size() << " matches\n";</pre>
         cout << "the matches were:" << endl;</pre>
         for (unsigned i=0; i<sm.size(); ++i) {</pre>
             cout << sm[i] << endl;</pre>
                                                          10
    return 0:
```

2 matches the matches were: version10 10

### 捕获和分组

- ■分组会按顺序标号
  - 0号永远是匹配的字符串本身
  - (a)(pple): 0号为apple, 1号为a, 2号为pple
  - 用(sub)(.\*)匹配subject: 0号为subject, 1号为sub, 2号为ject

- ■如果需要括号,又不想捕获该分组,可以使用 (?:pattern)
  - 用(?:sub)(.\*)匹配subject: 0号为subject, 1号为ject

用正则表达式^([a-z]+)(?:[A-Z]+)(\d+)\$匹配字符串"lzmSYY01",关于捕获到的分组的编号,下列说法正确的是:

- A 0号为lzm
- B 1号为SYY
- 2号为01
- **以上说法均不正确**

参考:

\d: 匹配所有单个数字

### 正则表达式库 <regex>

### ■捜索

- regex\_search(s, result, re):搜索字符串s中能够匹配正则表达式re的第一个子串,并将结果存储在result中
- result是一个smatch对象
- •对于该子串,分组同样会被捕获

### 搜索的例子

```
#include <iostream>
#include <string>
#include <regex>
using namespace std;
int main() {
   string s("this subject has a submarine");
   regex e(R"((sub)([\S]*))");
   smatch sm;
   //每次搜索时当仅保存第一个匹配到的子串
   while(regex_search(s,sm,e)){
      for (unsigned i=0; i<sm.size(); ++i)</pre>
          cout << "[" << sm[i] << "] ";
      cout << endl;</pre>
                                输出:
      s = sm.suffix().str();
                                [subject] [sub] [ject]
                                [submarine] [sub] [marine]
```

### 正则表达式库 <regex>

#### ■替换

- regex\_replace(s, re, s1): 替换字符串s中 所有匹配正则表达式re的子串,并替换成s1
- s1可以是一个普通文本

### 替换的例子

```
#include <iostream>
#include <string>
#include <regex>
using namespace std;

int main() {
    string s("this subject has a submarine");
    regex e(R"(sub[\S]*)");
    //regex_replace返回值即为替换后的字符串
    cout << regex_replace(s,e,"SUB") << "\n";
}</pre>
```

输出: this SUB has a SUB

### 正则表达式库 <regex>

#### ■替换

- regex\_replace(s, re, s1): 替换字符串s中 所有匹配正则表达式re的子串,并替换成s1
- s1可以是一个普通文本
- · 51也可以使用一些特殊符号,代表捕获的分组
  - \$& 代表re匹配的子串
  - \$1, \$2 代表re匹配的第1/2个分组

### 替换的例子

```
this SUBJECT has a SUBJECT
                         this [subject] has a [submarine]
                         this sub has a sub
#include <iostream>
                         this ject has a marine
#include <string>
                         this sub and [ject] has a sub and [marine]
#include <regex>
using namespace std;
int main() {
   string s("this subject has a submarine");
   regex e(R"((sub)([\S]*))");
   //regex_replace返回值即为替换后的字符串
   cout << regex_replace(s,e,"SUBJECT") << endl;</pre>
   //$&表示所有匹配成功的部分,[$&]表示将其用[]括起来
   cout << regex_replace(s,e,"[$&]") << endl;</pre>
   //$i输出e中第i个括号匹配到的值
   cout << regex_replace(s,e,"$1") << endl;</pre>
   cout << regex_replace(s,e,"$2") << endl;</pre>
   cout << regex_replace(s,e,"$1 and [$2]") << endl;</pre>
```

输出:

#### 下列代码的输出是:

```
#include <iostream>
#include <string>
#include <regex>
using namespace std;
```

```
参考:
```

\w: 匹配字母、数字、下划线

\s: 匹配所有空白字符

```
int main() {
    string s("hello girl hi cool");
    regex e(R"((\w+)\s+(\w+))");
    cout << regex_replace(s,e,"$2 $1");
}</pre>
```

- hello hi girl cool
- girl hello hi cool

- **B** girl hi cool hello
- girl hello cool hi

### 更多内容(自学)

#### ■预查

- 正向预查(?=pattern) (?!pattern)
- 反向预查(?<=pattern) (?<!pattern)

#### ■后向引用

- \b(\w+)\b\s+\1\b 匹配重复两遍的单词
- 比如go go 或 kitty kitty

#### ■贪婪与懒惰

- 默认多次重复为贪婪匹配, 即匹配次数最多
- 在重复模式后加? 可以变为懒惰匹配, 即匹配次数最少

# 结束